

Laboratório 02 - Inteligência Artificial

Algoritmos Bioinspirados: GA e PSO

Lucas Galvano

27 de Agosto de 2026

1 Introdução

Este relatório apresenta a resolução de dois problemas de otimização utilizando duas técnicas bioinspiradas: Algoritmo Genético (GA) e Otimização por Enxame de Partículas (PSO, do inglês *Particle Swarm Optimization*). O objetivo é comparar o desempenho das duas técnicas em um problema combinatório (mochila com repetições) e em um problema contínuo (busca de raízes de uma função), discutindo as adaptações necessárias em cada caso.

2 Problema 1: Mochila com Repetições

2.1 Definição

O problema consiste em escolher, dentre 5 tipos de itens, quantas cópias de cada um levar em uma mochila de capacidade 15 kg, maximizando o valor transportado. Diferente do problema clássico da mochila (0/1), aqui cada item pode ser escolhido um número ilimitado de vezes.

2.2 Adaptações necessárias

O material fornecido pelo professor contemplava um exemplo completo do problema **sem** repetições (indivíduo binário 0/1) e um template incompleto para o caso **com** repetições, o qual foi utilizado como base. As principais adaptações foram:

- **Representação:** o indivíduo/partícula deixou de ser um vetor binário (0 ou 1 por item) e passou a ser um vetor de **inteiros**, representando a quantidade de cada item escolhida.
- **Função de aptidão:** soma valor $\times$ quantidade e peso $\times$ quantidade de cada item. Como a maioria dos indivíduos aleatórios tende a ser inviável quando se permite repetição, foi utilizada uma **penalidade suave** (proporcional ao excesso de peso) em vez de zerar a aptidão de soluções inviáveis, o que evita que o algoritmo fique sem gradiente de melhoria.

- **GA — mutação:** sorteia uma nova quantidade para o gene escolhido, em vez de apenas inverter um bit.
- **PSO:** o exemplo do professor usava **BinaryPSO**, que não é compatível com quantidades repetidas. Foi utilizado **GlobalBestPSO** (contínuo), com limites por item e arredondamento do valor da partícula para o inteiro mais próximo dentro da função de aptidão.

2.3 Resultados

- **GA:** quantidades = [0, 11, 1, 0, 0] (11 unidades de cinza + 1 unidade de amarelo), valor total = 32, peso total = 15 kg (capacidade 15 kg).
- **PSO:** quantidades = [0, 3, 3, 0, 0] (3 unidades de cinza + 3 unidades de amarelo), valor total = 36, peso total = 15 kg (capacidade 15 kg).

O ótimo teórico do problema é 36 (3 unidades do item amarelo + 3 unidades do item cinza), e nesta execução foi o PSO que o encontrou exatamente, enquanto o GA ficou um pouco abaixo. Como nenhuma das duas técnicas utiliza uma semente (*seed*) fixa para o gerador de números aleatórios, execuções diferentes produzem resultados diferentes, e não há um vencedor consistente: em rodadas anteriores deste mesmo código, ora o GA encontrou o ótimo (36) e o PSO ficou abaixo (33), ora o oposto ocorreu, com os valores oscilando de forma geral entre 30 e 36 para ambas as técnicas.

2.4 Convergência

A Figura 1 mostra o melhor valor encontrado a cada geração (GA) / iteração (PSO). Ambas as curvas têm formato de "escada": por se tratar de um problema com variáveis inteiras, cada melhoria representa literalmente uma nova combinação de quantidades, e não um ajuste contínuo e gradual como seria em um problema de variáveis reais. As duas técnicas convergem rapidamente (a maior parte do ganho ocorre nas primeiras 10 gerações/iterações) e depois estagnam em um platô, o que é coerente com o espaço de busca relativamente pequeno deste problema (apenas 5 itens, com poucas combinações inteiras viáveis dentro do limite de 15 kg).




Figura 1: Convergência de GA e PSO no problema da mochila com repetições.

3 Problema 2: Raízes da Função

3.1 Definição

Encontrar, via Algoritmo Genético, valores de x , y e z no intervalo $[-10, 10]$ que sejam raiz da função:

$$f(x, y, z) = x^2 + y^2 + z^2$$

Como $f(x, y, z) = 0$ apenas em $(0, 0, 0)$, o problema foi tratado como a minimização de f .

3.2 Adaptações necessárias

Diferente do problema da mochila, não havia nenhum código-base fornecido pelo professor para este exercício — a representação e os operadores genéticos foram desenvolvidos integralmente:

- **Representação:** indivíduo como vetor de 3 números reais (x, y, z) .
- **Função de aptidão:** o próprio valor de $f(x, y, z)$, configurando `maximise_fitness=False` para que o GA busque minimizar.
- **Crossover:** aritmético (*blend*), combinando os genes dos pais com um peso aleatório — mais adequado a genes contínuos do que o corte-e-troca usado em vetores binários.
- **Mutação:** perturbação gaussiana em torno do valor atual do gene, permitindo refinar soluções já próximas do ótimo.

Adicionalmente, foi implementada uma versão em PSO do mesmo problema, já que o enunciado geral do laboratório pede a comparação entre as duas técnicas para ambos os problemas. Nesse caso, o PSO foi aplicado em seu formato contínuo nativo, sem necessidade de nenhuma adaptação discreta.

3.3 Resultados

- **GA:** $(x, y, z) \approx (-4,15 \times 10^{-5}; -8,81 \times 10^{-5}; -1,14 \times 10^{-3})$, $f(x, y, z) \approx 1,32 \times 10^{-6}$.
- **PSO:** $(x, y, z) \approx (2,80 \times 10^{-6}; 5,05 \times 10^{-6}; -1,30 \times 10^{-6})$, $f(x, y, z) \approx 3,50 \times 10^{-11}$.

3.4 Convergência

A Figura 2 mostra o melhor valor de $f(x, y, z)$ encontrado a cada geração/iteração, em escala logarítmica. O formato em "degraus" de ambas as curvas evidencia como cada técnica refina a solução: o GA melhora apenas quando a mutação gaussiana (aplicada a um único gene por vez, com desvio padrão fixo) produz, por acaso, uma perturbação favorável — por isso a curva do GA apresenta longos platôs (por exemplo, entre as gerações 35 e 60 nesta execução) intercalados com quedas abruptas. Já o PSO desce de forma mais consistente ao longo de toda a execução, já que todas as partículas se movem simultaneamente em direção ao melhor ponto do enxame a cada iteração, sem depender de uma mutação aleatória "acertar" a direção certa. Esse comportamento explica por que o PSO termina a execução cerca de 4 a 5 ordens de grandeza mais próximo do ótimo teórico ($f = 0$) do que o GA.




Figura 2: Convergência de GA e PSO no problema das raízes de $f(x, y, z) = x^2 + y^2 + z^2$ (escala logarítmica no eixo vertical).

4 Discussão

4.1 Qual técnica foi melhor para qual tipo de problema?

O PSO se saiu **consistentemente melhor** no problema contínuo (raízes) em todas as execuções realizadas, convergindo para um valor de $f(x, y, z)$ de 4 a 6 ordens de grandeza menor que o GA. Isso é esperado: o PSO foi originalmente concebido para otimização em espaços contínuos, onde as partículas se movem de forma suave em direção às melhores posições já encontradas, enquanto o refinamento fino do GA depende de uma mutação gaussiana "acertar" a direção certa por acaso (ver Seção 3 e Figura 2).

Já no problema combinatório (mochila com repetições), **não há um vencedor consistente entre execuções**: em uma rodada o GA atingiu o ótimo teórico (36) e o PSO ficou abaixo (33); em outra, foi o PSO que atingiu o ótimo (36) e o GA ficou abaixo (32). Isso sugere que, para problemas discretos com espaço de busca relativamente pequeno como este, as duas técnicas são comparáveis em qualidade de solução, e qual delas "vence" em uma execução específica tem mais a ver com sorte na inicialização aleatória do que com alguma vantagem estrutural de uma técnica sobre a outra.

4.2 Os resultados foram iguais?

Não de forma determinística: como nenhuma das duas técnicas garante encontrar o ótimo global nem usa semente fixa, execuções diferentes produzem soluções distintas em ambos os problemas. No problema da mochila, os valores finais de GA e PSO ficaram sempre próximos entre si (entre 30 e 36), alternando qual técnica chegou mais perto do ótimo a cada execução; já no problema das raízes, o PSO convergiu de forma consistente e significativamente mais perto de zero que o GA em todas as execuções realizadas.

4.3 Quais adaptações foram necessárias em cada caso?

Resumidamente:

- **Mochila com repetições:** indivíduo/partícula binário $\rightarrow$ vetor de inteiros; função de aptidão com penalidade suave em vez de corte abrupto; PSO binário $\rightarrow$ PSO contínuo com arredondamento.
- **Raízes:** nenhum código-base disponível; representação, fitness, crossover e mutação desenvolvidos do zero para genes contínuos; PSO aplicado em seu formato nativo, sem adaptações discretas.

5 Conclusão

Os experimentos reforçam que a escolha entre GA e PSO — e principalmente a forma como o problema é representado — tem impacto direto na qualidade

e velocidade de convergência da solução. Problemas com natureza contínua se beneficiam naturalmente do PSO, enquanto problemas combinatórios exigem maior cuidado no desenho da função de aptidão para ambas as técnicas, especialmente quando restrições (como a capacidade da mochila) tornam a maioria das soluções aleatórias inviáveis.

6 Código-fonte

O código-fonte completo desenvolvido para este laboratório está disponível no repositório:

<https://github.com/LucasGalvano/labsIA-CCI620>